CHALET AZURE ROMANDIE · JEUDI 29 OCTOBRE 2026 · GENÈVE

IA agentique : vers Azure et au-delà !

```
cloud: azure
```

```
cloud: au-delà
```

REX — architectures IA d'entreprise

AKS · écosystème Solo.io · Microsoft Foundry

Une plateforme d'agents robuste, gouvernée et prête pour l'entreprise : ce qui a marché, ce qui a fait mal.



Antoine LOIZEAU

Senior Cloud Architect · Smart Cloud Architect

Tesla Store Genève · Rue de la Confédération 8 · 18:00–21:00

QUI SUIS-JE



Antoine
LOIZEAU

Senior Cloud Architect · Freelance

Smart Cloud Architect
smartcloudarchitect.fr

MCT Microsoft Certified Trainer

MVP 2024 Azure Infrastructure as Code

Ce que je fais

Concevoir

`plateformes cloud sur Azure`

Réseau, AKS, identité, Infrastructure as Code — et depuis deux ans, des plateformes d'agents IA.

Partager

`blog.smartcloudarchitect.fr`

Retours d'expérience écrits, conférences, meetups — comme ce soir.

Transmettre

`formation et accompagnement`

Former les équipes jusqu'à ce qu'elles n'aient plus besoin de moi.

Le Terraform, les manifestes, les démos et les tableaux de bord de ce soir sont publiés.

UN VENDREDI SOIR

60 000 €

consommés en un week-end

Une clé API qui fuite. Aucune limite de consommation.
Personne pour regarder avant le lundi matin.

```
identité: partagée
limite: aucune
trace: aucune
```

LE DIAGNOSTIC

Ce qui manquait à nos agents



Identité

Qui appelle ?

Une clé partagée ne dit rien de la personne, de l'équipe ni de l'agent.



Limite

Combien ?

Aucun plafond, aucun budget par équipe, aucun coupe-circuit.



Trace

Quoi, avec quel outil ?

Aucune métrique par modèle, par consommateur ni par outil : on découvre la facture.

Une plateforme d'agents « prête pour l'entreprise », c'est d'abord ces trois réponses.

AU PROGRAMME

Cinq étapes, trois démos

01 — **Microsoft Foundry et les architectures IA d'entreprise**
Où Foundry s'arrête, où la plateforme commence

02 — **Déploiement et orchestration sur AKS**
Terraform, Workload Identity, deux portes

03 — **Solo.io Agent Gateway et Agent Registry** — DÉMO A
Jeton Entra, plafonds · garde-fous Foundry → NVIDIA NeMo · catalogue

04 — **kagent et le cycle de vie des agents** — DÉMO B
De la v0 à la v1 · une équipe « Agent Ready » en deux pipelines

05 — **REX, gouvernance et bonnes pratiques** — DÉMO C
Identité Entra ID, coûts et audit · socle de garde-fous

01

Microsoft Foundry et les architectures IA d'entreprise

étape: 01

AU PROGRAMME · Foundry · architecture de référence

Où Foundry s'arrête, où la plateforme commence.

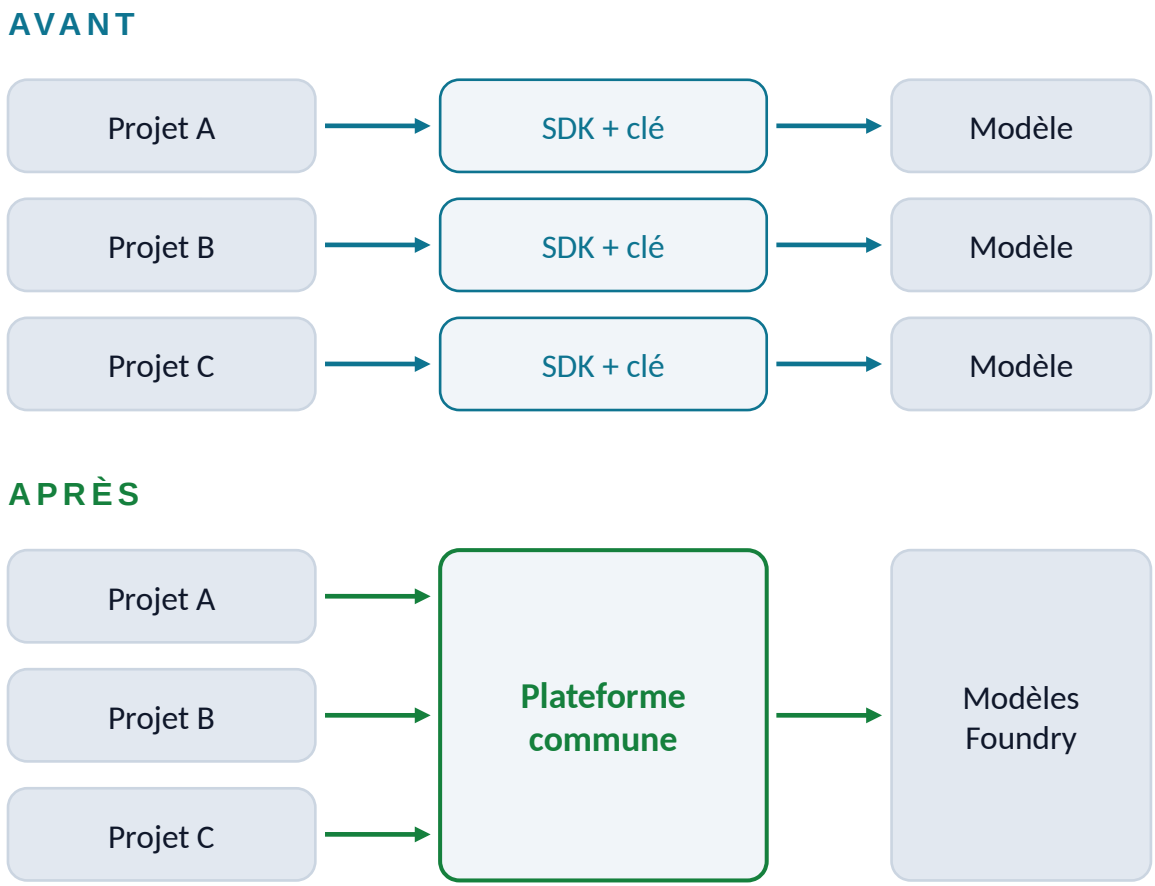
LE CONTEXTE

Chaque projet branchait son SDK et sa clé

Groupe média français

~3 000 collaborateurs

- Objectif : une plateforme agentique centralisée
- Un front unique au niveau du groupe
- Des connecteurs vers le SI : Jira, Azure DevOps, SharePoint…
- Point de départ : une intégration IA par projet, sans socle commun



ARCHITECTURE DE RÉFÉRENCE

Une architecture IA d'entreprise, ce sont cinq couches

Front	Où les gens travaillent	`LibreChat · Entra ID`
Agents	Ce que les équipes construisent	`kagent (CNCF Sandbox)`
Outils	Ce que les agents ont le droit de faire	`serveurs MCP · kmcp · catalogue agentregistry`
Passerelle	Qui, combien, quoi — pour tout le trafic	`agentgateway (Linux Foundation)`
Modèles	L'intelligence, interchangeable	`Microsoft Foundry · modèles dans AKS (KAITO)`

TRANSVERSE

Identité

Entra ID · Workload ID

Observabilité

Prometheus · Grafana

Gouvernance

politiques · catalogue

Livraison

Terraform · GitHub OIDC

La règle du REX : aucune couche ne parle directement à un fournisseur de modèles. Tout passe par la passerelle.

MICROSOFT FOUNDRY

Ce que nous prenons à Foundry

Un compte, un projet

Ressource AI Services + projet Foundry, déployés par Terraform azurerm.

Trois profils de modèle

gpt-5.6-sol (frontier, Global) · terra (quotidien, DataZone UE) · luna (volume, DataZone UE).

Sans clé

local_auth désactivé. La passerelle s'authentifie par Workload Identity, scope ai.azure.com.

Les garde-fous

Filtres de contenu et Prompt Shields sur chaque déploiement : ce qui tourne en production.

CE QUE NOUS N'EN ATTENDONS PAS

- L'exécution des agents : ils tournent dans AKS, à côté des données et des outils du SI
- Le contrôle d'accès des utilisateurs et des équipes : il vit à la passerelle, pour tous les modèles
- Le catalogue des outils : agentregistry, dans le cluster

Endpoint OpenAI v1, sans api-version. Le scope cognitiveservices.azure.com est remplacé par ai.azure.com.

LE CHOIX D'ARCHITECTURE

Foundry Agent Service ou plateforme AKS ?

	Foundry Agent Service	Plateforme sur AKS (ce REX)
Où tournent les agents	Service managé Azure (agents hébergés)	Votre cluster, à côté des outils du SI
Identité des agents	Entra Agent ID, natif	À construire : clés d'équipe, Workload ID
Garde-fous	Foundry, y compris appels et réponses d'outils (préversion)	À la passerelle, quel que soit le modèle
Modèles	Catalogue Foundry, passerelle IA APIM pour d'autres	Foundry, Bedrock, modèles dans AKS…
Exploitation	**Microsoft l'opère**	**Vous l'opérez**
Portabilité	Azure	**Tout Kubernetes**

Pas un camp à choisir : Foundry Control Plane sait inscrire des agents externes (A2A, via sa passerelle IA). Une piste pour faire voir nos agents kagent dans Foundry.

02

Déploiement et orchestration sur AKS

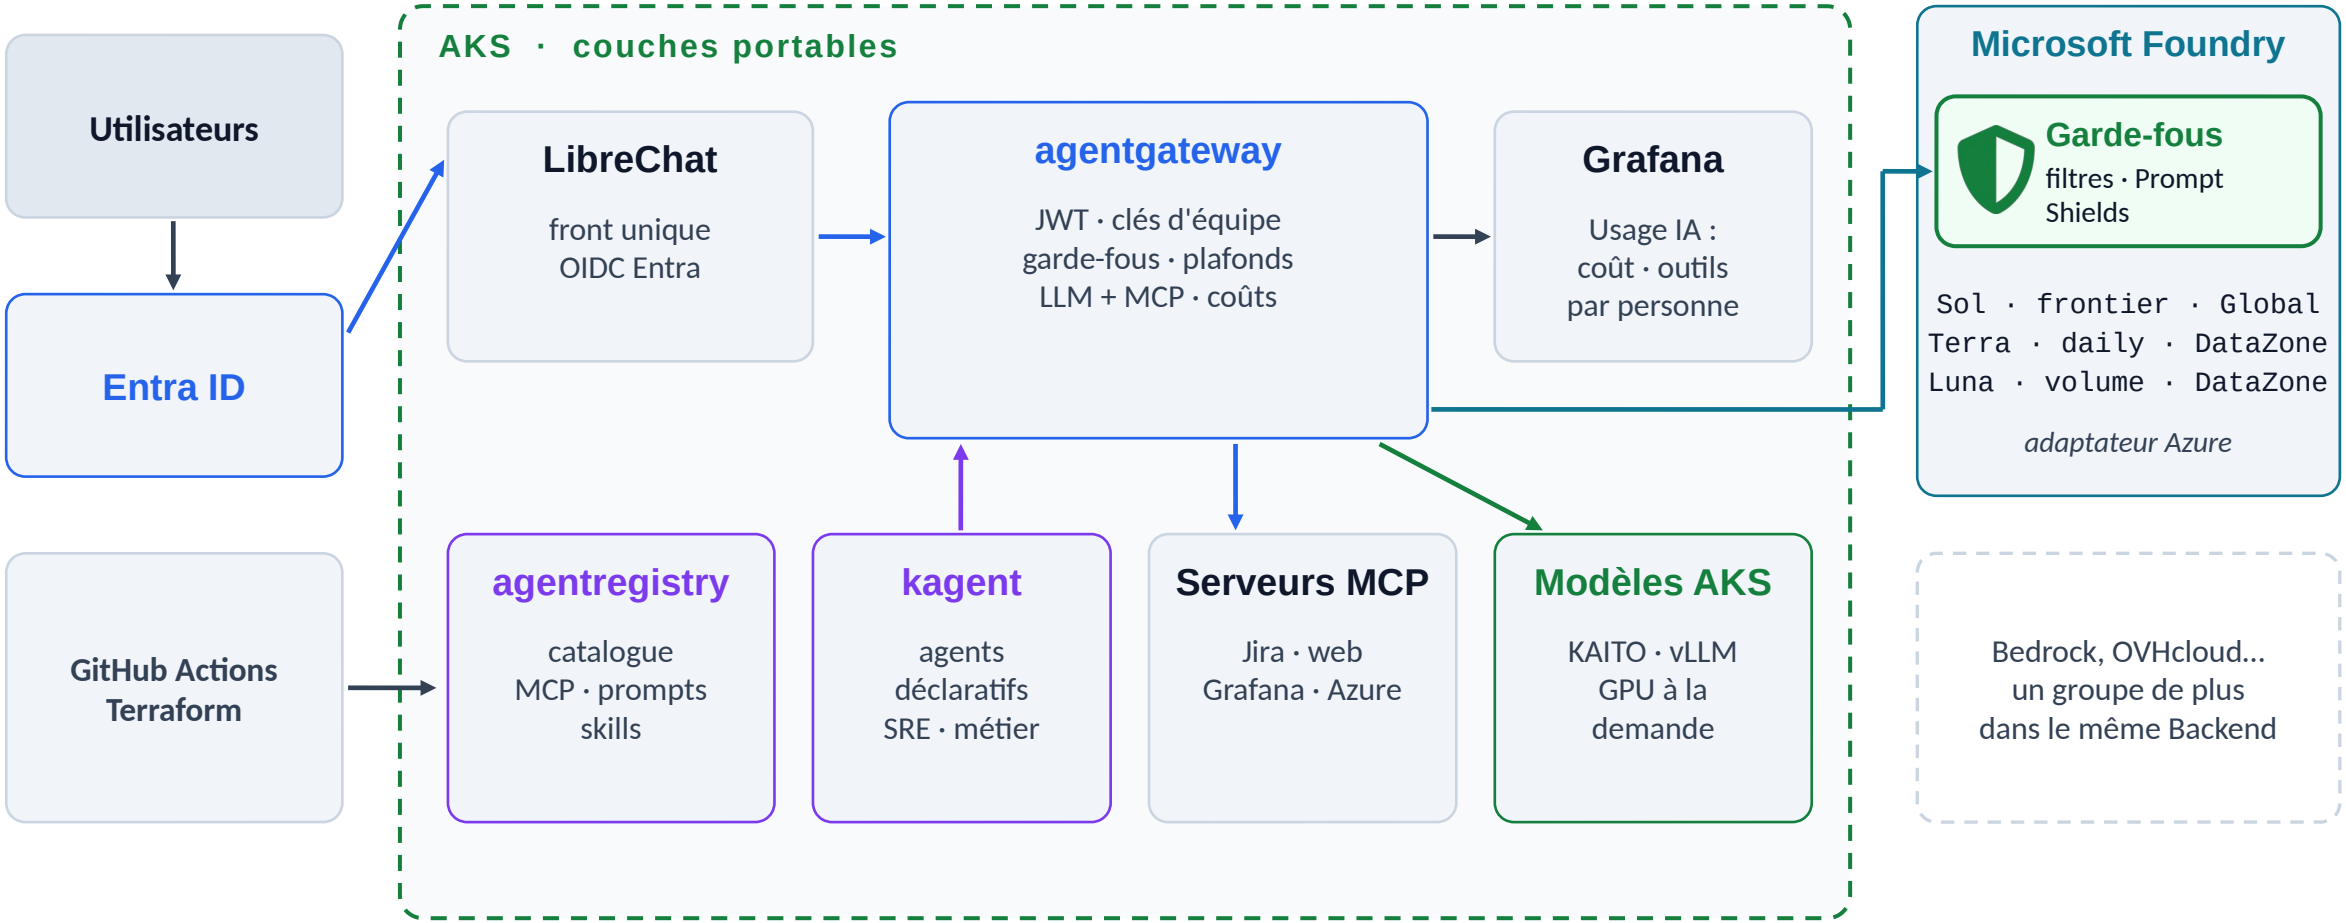
étape: 02

AU PROGRAMME · AKS · Terraform · Workload ID

Une plateforme qui sort de terre en un apply.

ARCHITECTURE

Tout ce qui est dans le cluster est portable



AKS

Ce que le cluster apporte à une plateforme d'agents

Workload Identity

Émetteur OIDC + identités managées fédérées : la passerelle appelle Foundry sans clé.

Deux portes

Gateway interne (ClusterIP) et publique (IP statique, Let's Encrypt, Entra ID devant chaque UI).

GPU à la demande

Add-on KAITO : un modèle ouvert dans le cluster, derrière la même passerelle.

Isolation

Cilium et NetworkPolicy : seuls les proxys atteignent garde-fous et modèles.

Tout part de Git

Terraform en deux phases (Azure, puis Helm), manifestes d'équipe en Kustomize. Prêt pour Argo CD ou Flux.

Zéro secret dans Git

GitHub Actions s'authentifie par OIDC fédéré ; l'état Terraform par Entra ID.

2 × D4as_v5, plan de contrôle Free : le socle du PoC ≈ 0,41 $ de l'heure, détruit après chaque session.

03

Solo.io Agent Gateway et Agent Registry

étape: 03

AU PROGRAMME ·
agentgateway · démo A ·
garde-fous · agentregistry

Un point de contrôle et un catalogue.

POURQUOI AGENTGATEWAY

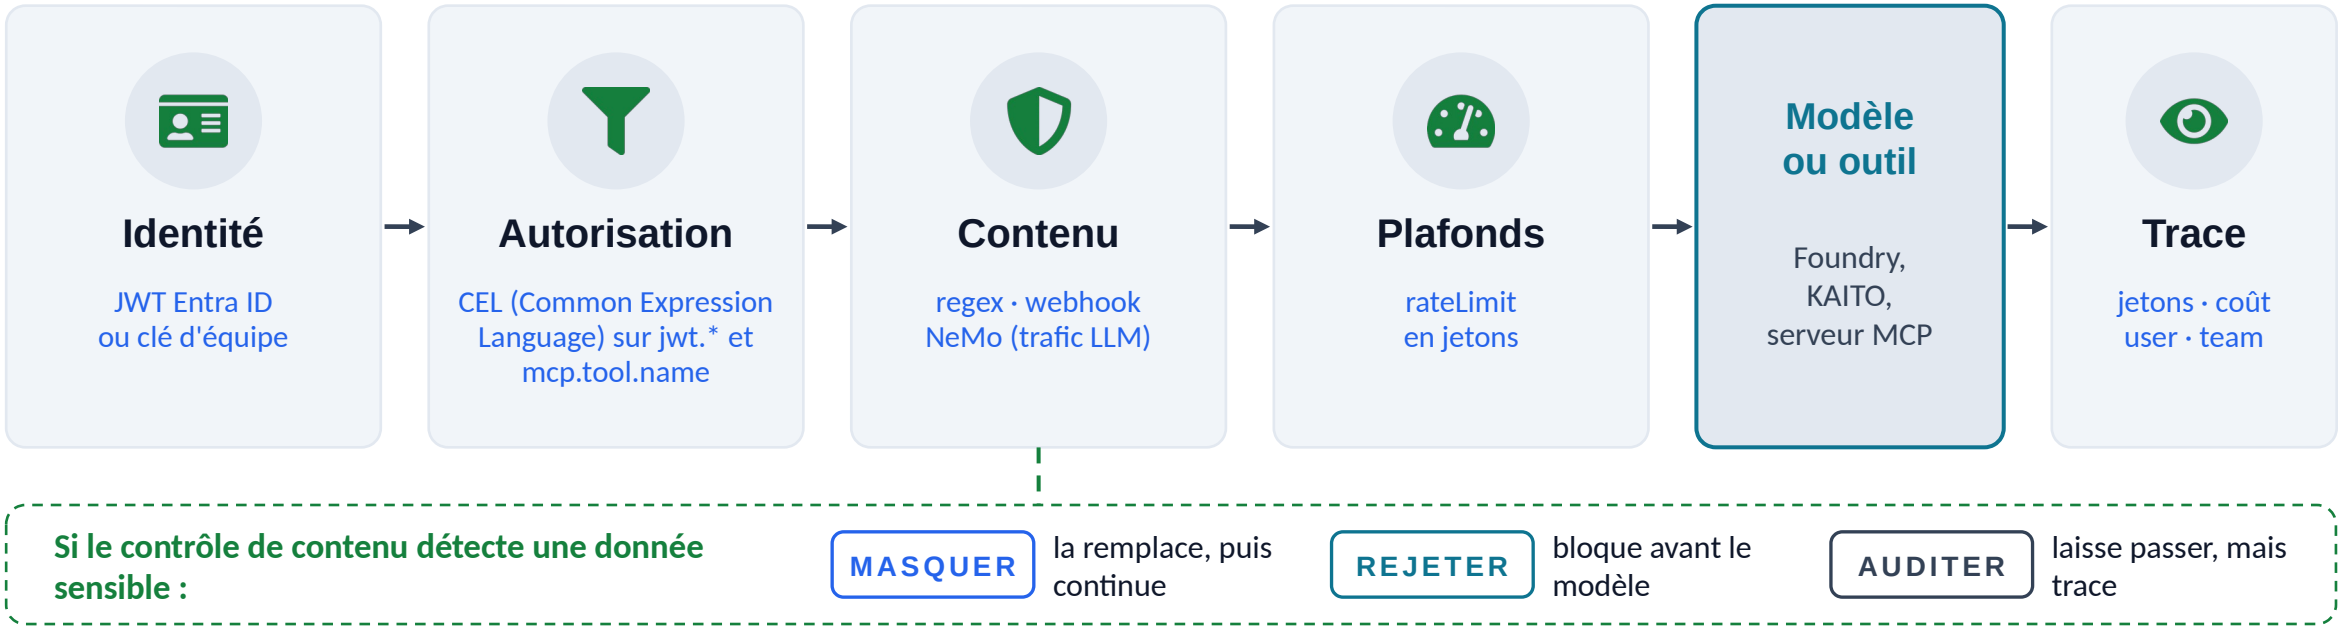
Trois candidats, trois terrains de prédilection

	Azure API Management	LiteLLM	agentgateway
Modèle de configuration	Ressources Azure + policies XML	config.yaml + état en base	CRD Kubernetes (Gateway API)
Créer un serveur MCP depuis une API REST	**Oui**	**Non**	**Non**
Fédérer N serveurs MCP derrière un endpoint	**Non**	**Oui**	**Oui**
Autorisation par outil MCP à l'exécution	**Non**	**Oui — par clé, équipe**	**Oui — CEL (Common Expression Language) sur le JWT**
Consommation par utilisateur	**Oui — métriques de jetons**	**Oui — dépenses en base**	**Oui — jetons et coût**
Portail développeur, produits, abonnements	**Oui**	Partiel	**Non**
Tourne hors Azure	Self-hosted gateway	**Oui**	**Oui**
Licence	Propriétaire	MIT + dossier enterprise	Apache-2.0 · Linux Foundation

Documentation officielle de chaque projet. Si votre point de départ est un patrimoine d'API REST, regardez APIM en premier ; pour une plateforme Kubernetes multi-fournisseurs, agentgateway.

UN POINT DE CONTRÔLE

Chaque requête traverse la même chaîne — LLM et outils



Aucune ligne dans les agents : changez de modèle ou de cloud, la chaîne suit.

DÉMO A

LIVE

Stopper l'usage illimité d'un LLM

demos/A-ratelimit-entra/*.yaml (simplifié)

```yaml
# 1 · une route ouverte « pour aller vite »
kind: HTTPRoute
spec:
  rules:
  - matches: [{ path: { value: /demo/v1 } }]
    backendRefs: [{ kind: AgentgatewayBackend, name: llm }]
---
# 2 et 3 · une politique, attachée à la route
kind: AgentgatewayPolicy
spec:
  targetRefs: [{ kind: HTTPRoute, name: llm-demo-ouverte }]
  traffic:
    jwtAuthentication:
      mode: Strict              # pas de jeton Entra : 401
      providers: [{ issuer: login.microsoftonline.com/… }]
    rateLimit:
      local:
      - tokens: 400             # jetons LLM par minute : 429
        unit: Minutes
```

Route ouverte

200, 200, 200 — n'importe qui consomme, personne ne sait qui.

+ jeton Entra ID

401 sans jeton ; avec, la passerelle sait QUI consomme.

+ plafond

429 au-delà de 400 jetons/min — la dépense s'arrête.

Qui a consommé quoi

Grafana « Usage IA » : coût, 401 et 429, par personne.

SÉCURISER LES LLM · ÉTAPE 1

EN PROD

Les garde-fous de Microsoft Foundry

Contenus nuisibles

haine, sexuel, violence, auto-mutilation — seuil par catégorie

Prompt Shields

attaques par le prompt (jailbreak) et attaques indirectes cachées dans les documents

Données sensibles

détection de PII, listes de blocage personnalisées

Matériel protégé, ancrage

texte et code sous droits · réponses non fondées (groundedness)

Efficaces et natifs, mais attachés à chaque déploiement Azure : ils ne voient pas les appels d'outils de nos agents kagent et ne suivent pas un changement de fournisseur.

POINTS D'INTERVENTION

Entrée utilisateur	modèles et agents
Appel d'outil	agents Foundry seulement · préversion
Réponse d'outil	agents Foundry seulement · préversion
Sortie	modèles et agents

ET CLAUDE ?

Les modèles Anthropic du catalogue Foundry n'ont aucun filtre de contenu Foundry : seules les protections d'Anthropic s'appliquent.

R&D

NVIDIA NeMo Guardrails, derrière la passerelle



CINQ FAMILLES DE RAILS

Entrée	rejeter ou réécrire le prompt (masquer)
Dialogue	cadrer ce que l'assistant a le droit de faire
Récupération	filtrer les extraits d'un RAG
Exécution	contrôler l'entrée et la sortie des outils
Sortie	rejeter ou corriger la réponse

Ce que contient le dépôt

- Profil default : secrets, IBAN, NIR, injection (YARA) — < 10 ms, aucun appel LLM
- Profil strict : + self check input/output par un LLM
- Fail-closed : sans adaptateur, aucun trafic LLM
- 20 tests, contrat webhook validé

Open source (Apache-2.0) en mode bibliothèque. Le mode microservice (NIM Operator) relève de la licence NVIDIA AI Enterprise.

DÉFENSE EN PROFONDEUR

Qui protège quoi ?

	Garde-fous Foundry	Passerelle : regex natif	Passerelle : webhook NeMo
Prompt et réponse vers Foundry	**Oui**	**Oui**	**Oui**
Prompt vers un modèle KAITO ou Bedrock	Non	**Oui**	**Oui**
Prompt vers Claude (Foundry, offre Anthropic)	Non — protections Anthropic seules	**Oui, s'il passe par la passerelle**	**Oui, s'il passe par la passerelle**
Appels d'outils de nos agents kagent	Non — agents hors Foundry	Indirect : résultats renvoyés au modèle	Indirect, avec des profils dédiés
Jailbreak, injection indirecte	**Oui — Prompt Shields**	Motifs connus seulement	**Oui — YARA, self-check**
Données métier (IBAN, NIR, secrets)	PII générique	**Motifs simples**	**Profils de règles**
Statut chez le client	**En production**	**En production**	R&D

La règle de référence vit à la passerelle ; les filtres natifs restent la deuxième ligne. Un modèle ou un outil appelé en direct échappe aux deux.

AGENT REGISTRY

Le catalogue des briques IA de l'entreprise

Serveurs MCP	npm, PyPI, image OCI ou endpoint distant
Agents	images construites avec arctl
Skills	SKILL.md et scripts, depuis Git
Prompts	versionnés, partagés
Modèles	fournisseur, endpoint, authentification

1. **Versionner**
   chaque entrée a ses tags : 1.0.0, v2, stable…
2. **Déployer**
   runtime Kubernetes → ressources kagent / kmcp dans le namespace de l'équipe
3. **Découvrir**
   CLI arctl, interface web, et un serveur MCP pour les agents eux-mêmes
4. **Gouverner**
   l'équipe plateforme déclare où chaque équipe peut déployer

v0.4.0 (août 2026), Apache-2.0. L'édition open source n'a pas d'authentification : jamais exposée, ClusterIP et droits limités aux namespaces d'équipe.

04

kagent et le cycle de vie des agents

étape: 04

AU PROGRAMME · kagent · cycle de vie · démo B

De la v0 à la v1 · une équipe « Agent Ready » en deux pipelines.

KAGENT · CNCF SANDBOX

Un agent, ce sont quelques ressources Kubernetes

Agent

`kagent.dev/v1alpha2`

Le rôle, le runtime, les outils autorisés. Un manifeste déclaratif.

Prompt

`systemMessageFrom`

Dans une ConfigMap : relu en PR, versionné, alimenté par le catalogue.

Skills

`spec.skills`

Images OCI ou dépôts Git avec un SKILL.md, montés dans /skills.

Outils MCP

`RemoteMCPServer` · `MCPServer`

Serveurs distants, ou déployés par kmcp dans le cluster.

Modèle

`ModelConfig`

Pointe vers la passerelle, jamais directement vers un fournisseur.

agentregistry

`le catalogue`

Publie, versionne et déploie serveurs MCP, prompts et skills.

Une équipe ne livre plus « son intégration IA » : elle livre des ressources que la plateforme sait valider, déployer, observer et retirer.

ANATOMIE D'UN AGENT

Tout ce qui fait l'agent tient dans un manifeste

terraform/teams/template/agent/agent.yaml (simplifié)

```yaml
apiVersion: kagent.dev/v1alpha2
kind: Agent
metadata:
  name: assistant-docs
  namespace: equipe-docs
spec:
  type: Declarative
  declarative:
    modelConfig: passerelle-llm   # (1)
    systemMessage: |              # (2)
      Tu es l'assistant documentaire de l'équipe.
      Réponds uniquement à partir de ses documents,
      cite toujours le document source.
    tools:
    - type: McpServer
      mcpServer:                  # (3)
        kind: RemoteMCPServer
        name: docs-mcp
        toolNames: [lister_documents, lire_document, rechercher]
        # requireApproval: [<outil qui écrit>]   (4)
```

1 **Modèle abstrait**

La passerelle choisit le fournisseur ; l'agent l'ignore et n'a pas de clé fournisseur.

2 **Prompt versionné**

Dans le dépôt de l'équipe, relu en pull request, sans rebuild.

3 **Outils filtrés**

Le serveur MCP de l'équipe ; l'agent ne voit que les outils listés.

4 **Validation humaine**

Les outils qui écrivent attendent un humain avant de s'exécuter.

ALPHA

kagent 1.0 : fin du type Declarative, place au Harness

	kagent 0.10 (stable, utilisé ici)	kagent 1.0 (alpha)
API	kagent.dev/v1alpha2	api.kagent.dev/v1alpha3 — nouveau groupe, installation neuve
Modèle	Agent type Declarative (tout dans un objet) ou BYO	Plus de Declarative : Agent = AgentTemplate (quoi) + Harness (comment)
Runtimes	ADK Python ou Go	Harness kagent (ADK), Codex, Claude ou BYO
BYO	N'importe quelle image servant A2A sur :8080, spec façon Deployment (replicas, volumes, env, service account)	Image épinglée par digest sha256 + command obligatoire ; contrat A2A gRPC privé, /readyz et TaskStore kagent
Exécution	Un Deployment par agent	Substrate : sessions durables, suspension, reprise, checkpoint et fork
Secrets	Secrets montés dans le pod	Injectés à la sortie par la passerelle d'egress Substrate : jamais dans l'agent
Outils	MCPServer ou RemoteMCPServer, requireApproval par outil	RemoteMCPServer seulement ; requireApproval par liaison

Pour ce talk : 0.10.x en production, 1.0 en essai. Un agent BYO d'aujourd'hui (une image A2A quelconque) ne tourne pas tel quel en 1.0.

ALPHA

Du manifeste Declarative au trio Template · Harness · Agent

demos/extras/cycle-de-vie-registre/agent.yaml

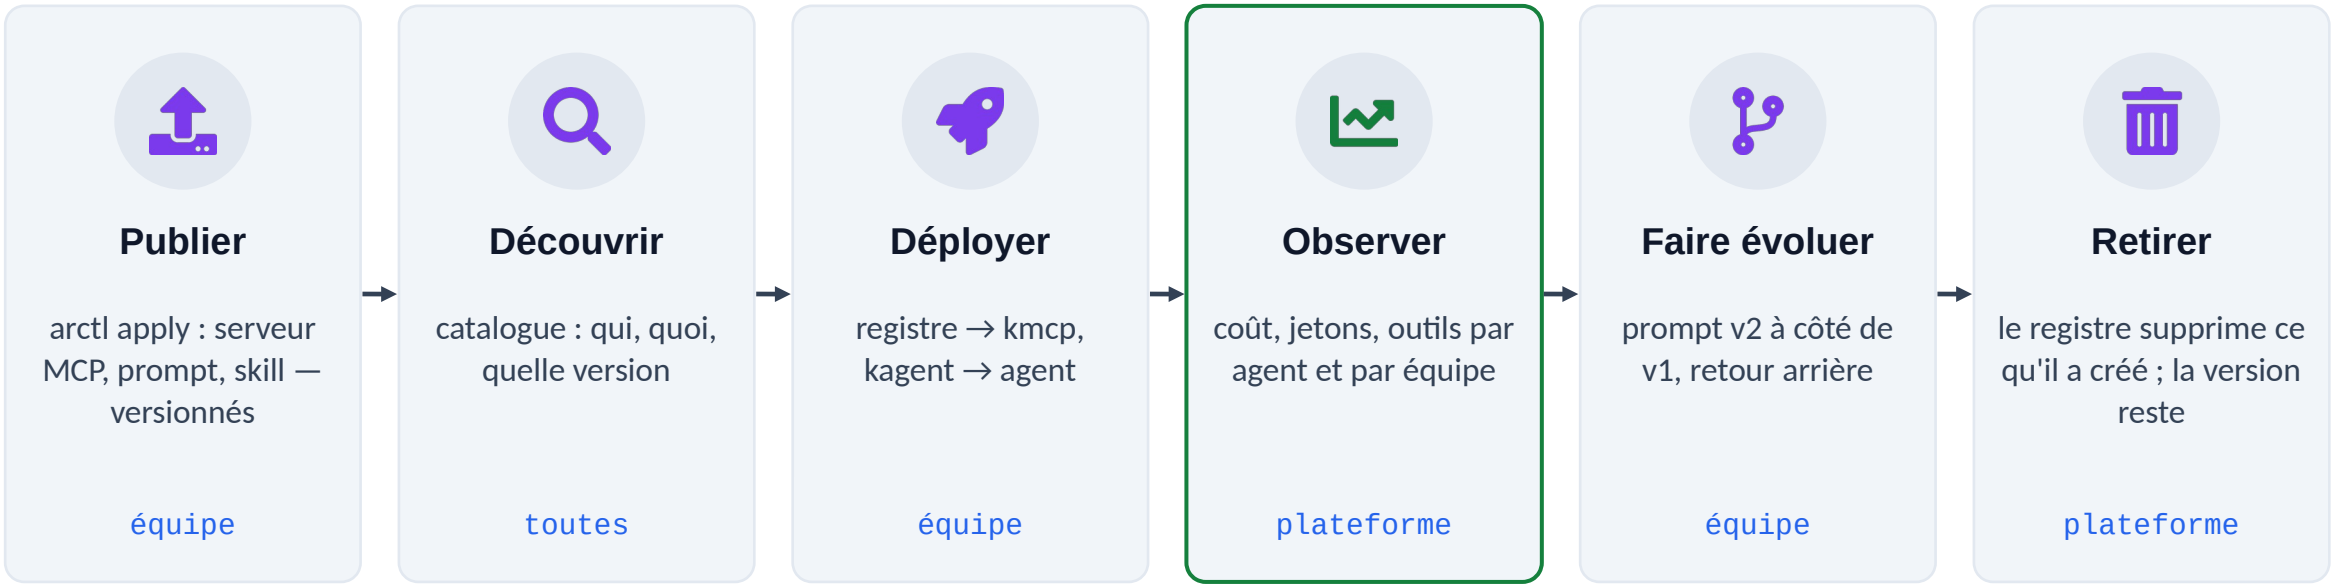
```yaml
# kagent 0.10 — un seul objet
apiVersion: kagent.dev/v1alpha2
kind: Agent
metadata:
  name: assistant-tickets
spec:
  type: Declarative
  declarative:
    modelConfig: passerelle-llm
    systemMessageFrom:
      type: ConfigMap
      name: prompt-assistant-tickets
      key: prompt
    tools:
    - type: McpServer
      mcpServer:
        kind: MCPServer
        name: jira-mcp-tickets
        toolNames: [jira_search, jira_get_issue]
# le runtime ? implicite (image ADK du chart)
```

demos/extras/cycle-de-vie-registre/kagent-v1/…

```yaml
# kagent 1.0 — QUOI : réutilisable entre agents
kind: AgentTemplate            # api.kagent.dev/v1alpha3
spec:
  modelConfig: { name: passerelle-llm }
  systemPromptFrom: { name: prompt-assistant-tickets, key: prompt }
  tools:
  - mcp:
      server: { kind: RemoteMCPServer, name: jira-mcp }
      tools: [jira_search, jira_get_issue]
---
# COMMENT : un runtime par classe d'agents
kind: Harness
spec:
  kagent: {}                   # ou codex, claude, byo
  workload:
    image: …/golang-adk@sha256:…   # digest obligatoire
  substrate: { workerPoolRef: …, snapshotPolicy: … }
---
# LE LIEN : ce comportement, avec ce runtime
kind: Agent
spec: { templateRef: { name: assistant-tickets },
        harnessRef:  { name: adk-go } }
# même template + autre harness = même agent, autre runtime
```

CYCLE DE VIE

Publier, découvrir, déployer, faire évoluer, retirer



Un gabarit par type d'agent

Les équipes partent d'un modèle validé, pas d'une page blanche.

Chaque version reste traçable

Qui a publié quel prompt, quel outil tourne où.

Identique sur tous les clusters

AKS, EKS ou Managed Kubernetes : le chemin ne change pas.

DÉMO B

VIDÉO

« Agent Ready » : l'équipe IA prépare, l'équipe de dev déploie

ÉQUIPE IA · AGENT READY

- pipeline GitHub à la demande, approbation « ai-team »
- Terraform, un état par équipe :
- 2 identités fédérées (pipeline · serveur MCP)
- stockage Entra ID seulement · 4 rôles
- namespace, quota, clé virtuelle, RoleBinding
- dépôt agent-<équipe> + ses variables

DEV · 1 · IMAGE

- push sur mcp/ (ou à la main)
- uses: …/agent-image.yml
- docker build → registre de la plateforme
- rôle AcrPush, rien d'autre

DEV · 2 · DÉPLOIEMENT

- après l'image, ou push agent/ docs/
- uses: …/agent-deploy.yml
- docs → stockage · kubectl apply dans SON namespace
- passerelle : serveur MCP découvert ; LibreChat répond

LE GABARIT · dépôt agent-<équipe>

Kustomize, pas de chart Helm — Helm reste côté plateforme

`mcp/`

serveur MCP : code + Dockerfile

`deploy/`

ServiceAccount fédéré, MCP, NetworkPolicy, RemoteMCPServer

`agent/`

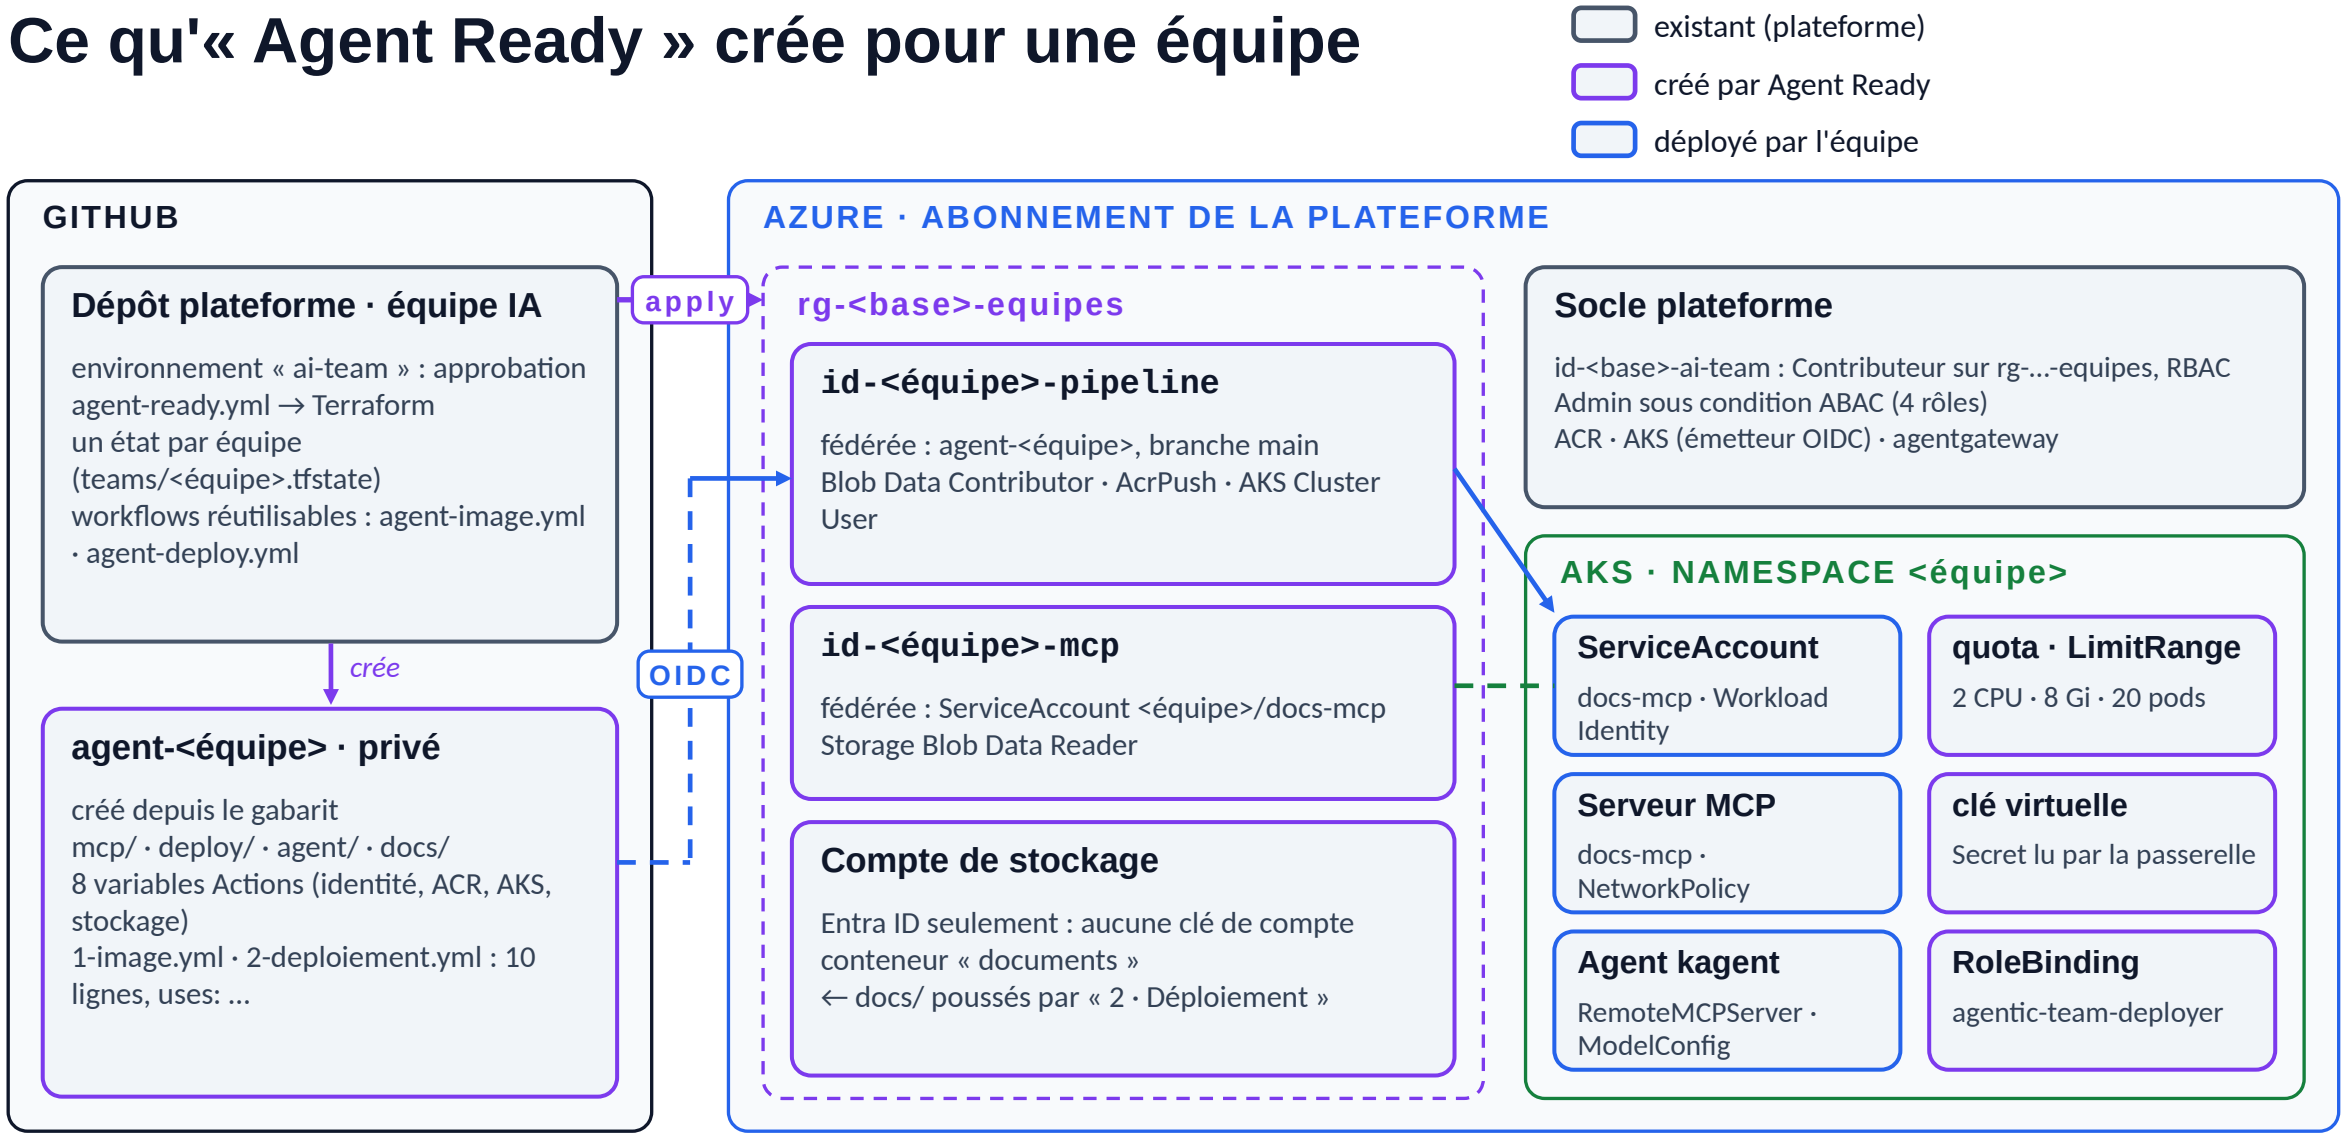
Agent + ModelConfig vers la passerelle

`docs/`

le contenu métier de l'équipe

DÉMO B · ARCHITECTURE

Ce qu'« Agent Ready » crée pour une équipe



TROIS IDENTITÉS, TROIS PÉRIMÈTRES

Aucun secret, et des droits taillés pour chaque geste

Identité	Fédérée avec	Azure	Kubernetes
Pipeline Agent Ready	environnement « ai-team » du dépôt plateforme — approbation	Contributeur sur rg-...-equipes ; RBAC Admin sous condition ABAC : 4 rôles, identités de service	agentic-team-provisioner, borné aux namespaces d'équipe par une politique d'admission
Pipelines de l'équipe	branche main de agent-<équipe> (même via les workflows réutilisables)	écrire SON stockage, AcrPush, AKS Cluster User	agentic-team-deployer dans SON namespace : ni Secrets, ni RBAC
Serveur MCP de l'équipe	ServiceAccount <équipe>/docs-mcp	lire SON stockage	—

Limite assumée : Terraform relit les Secrets qu'il gère — l'identité Agent Ready lit les Secrets du cluster ; l'admission borne les écritures, pas les lectures.

Même mal configuré, un pipeline d'équipe ne peut toucher ni une autre équipe, ni la plateforme — Azure et Kubernetes refusent.

05

REX, gouvernance et bonnes pratiques

Ce qui a fait mal, ce que je referais.

étape: 05

AU PROGRAMME · Entra ID · coûts · garde-fous · démo C

REX · IDENTITÉ ENTRA ID

Chaque outil a sa propre idée de l'identité

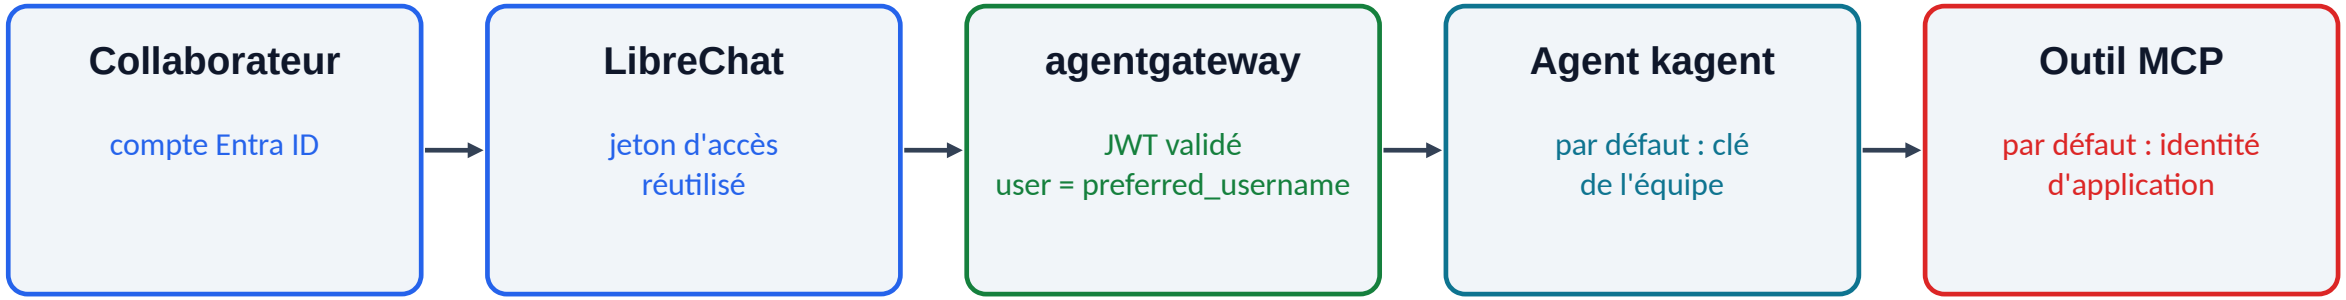
Outil	Symptôme	Cause	Correction
Passerelle	401 avec un jeton valide	jeton v1 : aud = api://<id> au lieu du GUID	requested_access_token_version = 2
LibreChat	« Échec de l'authentification »	le jeton réutilisé n'avait pas l'audience de l'API passerelle	OPENID_AUDIENCE + scope API · v0.8.8 (RC)
Grafana	« Unauthorized » après connexion	oauth2-proxy envoie un en-tête Basic que Grafana prend pour un login	pass-basic-auth = false
UI kagent	piège évité : scope invalide	le sous-chart oauth2-proxy demande « groups », refusé par Entra ID	scope openid profile email
Outils MCP	tout le monde voit tout	Graph et Azure en identité d'application, GitHub en OAuth direct	à traiter : délégation (OBO)
Agents	« qui a demandé ? »	clé d'équipe : l'utilisateur derrière invoke_agent est perdu	piste : Entra Agent ID
agentregistry	aucune authentification	édition open source	ClusterIP, port-forward

Le login fonctionne partout. C'est la propagation de l'identité d'un outil à l'autre qui coûte des jours.

REX · IDENTITÉ DE BOUT EN BOUT

À VALIDER

L'identité peut aller jusqu'à l'outil — pas toute seule



✔ identité intacte

✖ rupture, dans la configuration par défaut

① Passerelle → agent

Après validation, la passerelle retire le JWT. backendAuth « passthrough » le transmet à l'agent.

② Agent → outil

kagent 0.10 relaie le jeton de l'appelant : allowedHeaders [Authorization] sur le RemoteMCPServer.

③ Outil → Graph, Azure…

Le JWT vise la passerelle, pas Graph : il faut un échange de jeton (on-behalf-of).

Même bout en bout, les appels LLM de l'agent restent facturés à la clé de l'équipe.

REX · COÛTS ET AUDIT

Personne, équipe ou application : qui consomme ?

Appelant	Identité vue par la passerelle	Libellés sur chaque métrique	Ce qu'on peut refacturer
Collaborateur via LibreChat	JWT Entra ID	`user = preferred_username · team = collaborateurs`	à la personne, au département
Agent d'équipe	clé virtuelle de l'équipe	`user = agent:<équipe> · team = <équipe>`	à l'équipe
Agent appelé par un utilisateur	outil : JWT · LLM de l'agent : clé	`agent = <ns>/<nom> sur l'appel d'outil`	partiel : la chaîne se coupe
Outil appelé en direct	—	—	invisible

Le prix est une donnée à maintenir

Grille par modèle, déploiement et modèle servi ; prix DataZone non publiés → estimation au prix Global.

La cardinalité a un coût

Un libellé par personne : parfait pour un pilote ; à 3 000 personnes, l'équipe en Prometheus, le détail en journaux.

Plafond ≠ budget

Le plafond local est par route ; un budget par équipe demande le rate limit global et un service externe.

OBSERVABILITÉ

Le tableau de bord « Usage IA »

Vue d'ensemble

coût · projection 30 j · jetons · utilisateurs actifs · appels d'outils

Par utilisateur

coût, requêtes, jetons et outils par personne et par équipe · top 10

Par équipe et par modèle

coût par équipe, par déploiement · latence · premier jeton

Outils MCP

outils appelés · agents sollicités · qui utilise quoi

Accès et garde-fous

401 · 429 · contrôles par action · réponses sans prix

Skills

invisibles à la passerelle : traces OpenTelemetry de kagent

PromQL

```
# coût par personne sur la période
sum by (user, team) (
  increase(

agentgateway_gen_ai_client_cost_usd_tota
l
   [$__range]))

# outils appelés par personne
sum by (user, resource) (
  increase(
   agentgateway_mcp_requests_total
   {method="tools/call"}[$__range]))
```

Provisionné par Terraform (dossier Plateforme IA), généré par monitoring/src/usage_dashboard.py.

GOUVERNANCE

L'outil applique une politique. Il ne la remplace pas.



Qui a droit à quel modèle ?

Groupes Entra ID → politiques de la passerelle



Quel budget pour quelle équipe ?

Clés virtuelles, plafonds, tableau de bord



Quelles données vers quel outil ?

Garde-fous, outils publiés derrière la passerelle



Qui crée, valide et retire un agent ?

Catalogue, revue, runtime par équipe

Chaque réponse est d'abord une décision de gouvernance — puis une ressource Kubernetes.

Le catalogue natif de NeMo Guardrails, et ce qu'il bloque

Famille	Rails natifs (flows)	Étape	Réaction si détecté	Coût	Dépôt
Motifs regex	`regex check input · output · retrieval`	E · S · R	**Refuser · R : extrait retiré**	**déterministe**	**default · strict**
Injection (YARA)	`injection detection`	S	**Refuser ou retirer (omit)**	**déterministe**	**default · strict**
Taille du contexte	`context bloat detection on input · on retrieval`	E · R	**Refuser, tronquer, avertir**	**déterministe**	—
Appels d'outils	`tool call validation · tool result validation`	Outils	**Refuser (nom, schéma JSON)**	**déterministe**	—
Jailbreak	`jailbreak detection heuristics · model`	E	**Refuser**	**modèle dédié**	—
Données personnelles	`mask sensitive data on input · output · retrieval`	E · S · R	**Masquer (Presidio)**	**modèle dédié**	—
Contenu nuisible	`content safety check input · output $model=…`	E · S	**Refuser**	**modèle dédié**	—
Hors sujet	`topic safety check input $model=topic_control`	E	**Refuser**	**modèle dédié**	—
Auto-contrôle	`self check input · self check output`	E · S	**Refuser**	**appel LLM**	**strict**
Hallucination	`self check facts · self check hallucination`	S	**Refuser ou avertir**	**appel LLM**	—

REFUSER le tour s'arrête : 403 à la passerelle

MASQUER la donnée est anonymisée

RETIRER contenu fautif retiré ou tronqué

AVERTIR passe, avec un avertissement

E entrée · S sortie · R extraits récupérés (RAG) · Outils : appels et résultats d'outils. Bibliothèque Apache-2.0 ; rails tiers (Llama Guard, Presidio, Cisco AI Defense…) par configuration.

Règles fournies et extension : Foundry face à NeMo

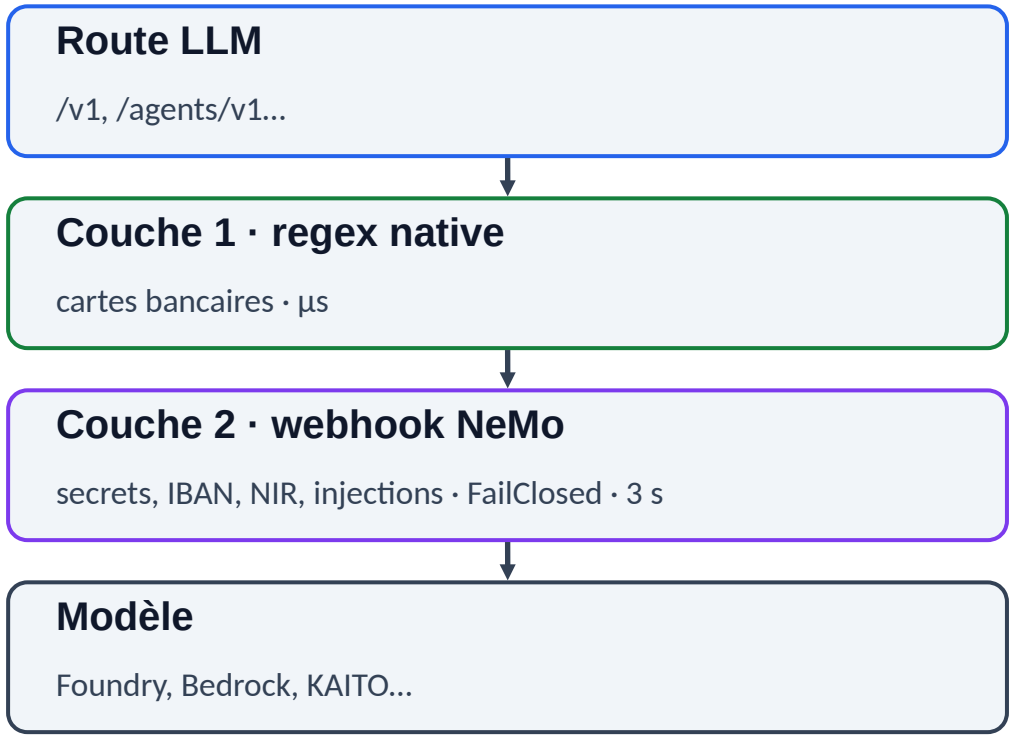
	Microsoft Foundry · garde-fous	NVIDIA NeMo Guardrails
Règles fournies	4 catégories (haine, sexuel, violence, auto-mutilation), Prompt Shields direct et indirect, matériel protégé texte et code, grossièretés · préversion : PII, ancrage, adhérence à la tâche	10 familles natives (slide précédente) et plus de 20 intégrations tierces : Llama Guard, Presidio, Cisco AI Defense…
Niveaux de blocage	4 niveaux par catégorie : Off · Low · Medium · High — Medium par défaut, bloque « moyen » et « élevé »	Par rail : refuser, masquer, retirer ou tronquer, avertir · seuils réglables (perplexité, taille, score)
Actions	Annoter, ou annoter et bloquer · annoter seulement, ou couper un filtre en sortie : sur approbation Microsoft	Choisies dans config.yml, sans approbation
Regex	Listes de blocage : terme exact ou regex, 10 000 termes par liste · modèles Azure OpenAI seulement	regex check input · output · retrieval : les motifs dans config.yml
Règles métier propres	Aucun code dans le garde-fou · une classification sur mesure passe par une API à part (Content Safety)	Rails Colang et actions Python : n'importe quelle règle, n'importe quel modèle de contrôle
Points d'intervention	Entrée et sortie · appel et réponse d'outil pour les agents Foundry (préversion)	Entrée, sortie, extraits RAG, dialogue, appels et résultats d'outils
Modèles couverts	Modèles vendus par Azure, agents Foundry Agent Service · ni Claude, ni nos agents kagent	Tout modèle derrière la passerelle : Foundry, Claude, Bedrock, KAITO
Exploitation	Managé et inclus · 50 à 100 ms par point d'intervention activé	À héberger : adaptateur et modèles de contrôle · < 10 ms en profil default

Foundry : on règle sans coder, sur ses propres modèles. NeMo : on code ses règles, pour tous les modèles. On empile les deux.

DÉMO C

LIVE

Le socle standard de garde-fous : NeMo derrière la passerelle



Prompt	Avant	Après
Clé d'API collée	200 — jusqu'au modèle	403 — NeMo
Numéro de sécurité sociale	200 — jusqu'au modèle	403 — NeMo
Numéro de carte	rejeté — couche 1	rejeté — couche 1
Prompt normal	200	200 — < 10 ms de garde-fous

Une règle à la passerelle, quel que soit le fournisseur — y compris Claude dans Foundry, sans filtre Foundry.

Adaptateur arrêté : la passerelle refuse tout. Pas de garde-fou, pas de trafic LLM.

BONNES PRATIQUES

Ce que je referais dès le premier jour

1

Aucune clé fournisseur hors de la passerelle

Agents et fronts parlent à une route, jamais à un modèle.

2

Des jetons d'accès v2, des rôles par GUID

requested_access_token_version = 2 ; rôles Foundry assignés par identifiant.

3

Sans secret de bout en bout

Workload Identity pour Foundry et les outils Azure ; OIDC pour la CI.

4

Les règles à la passerelle, les filtres natifs en plus

Une règle, tous les modèles ; Foundry en deuxième ligne.

5

Tout outil d'entreprise derrière la passerelle

Sinon il échappe aux garde-fous, au comptage et à l'audit.

6

Imputer les coûts à l'équipe d'abord

Un libellé par personne multiplie les séries Prometheus : la personne va dans les journaux.

7

Le catalogue avant le self-service

Ce qui n'est pas publié et versionné ne se déploie pas.

8

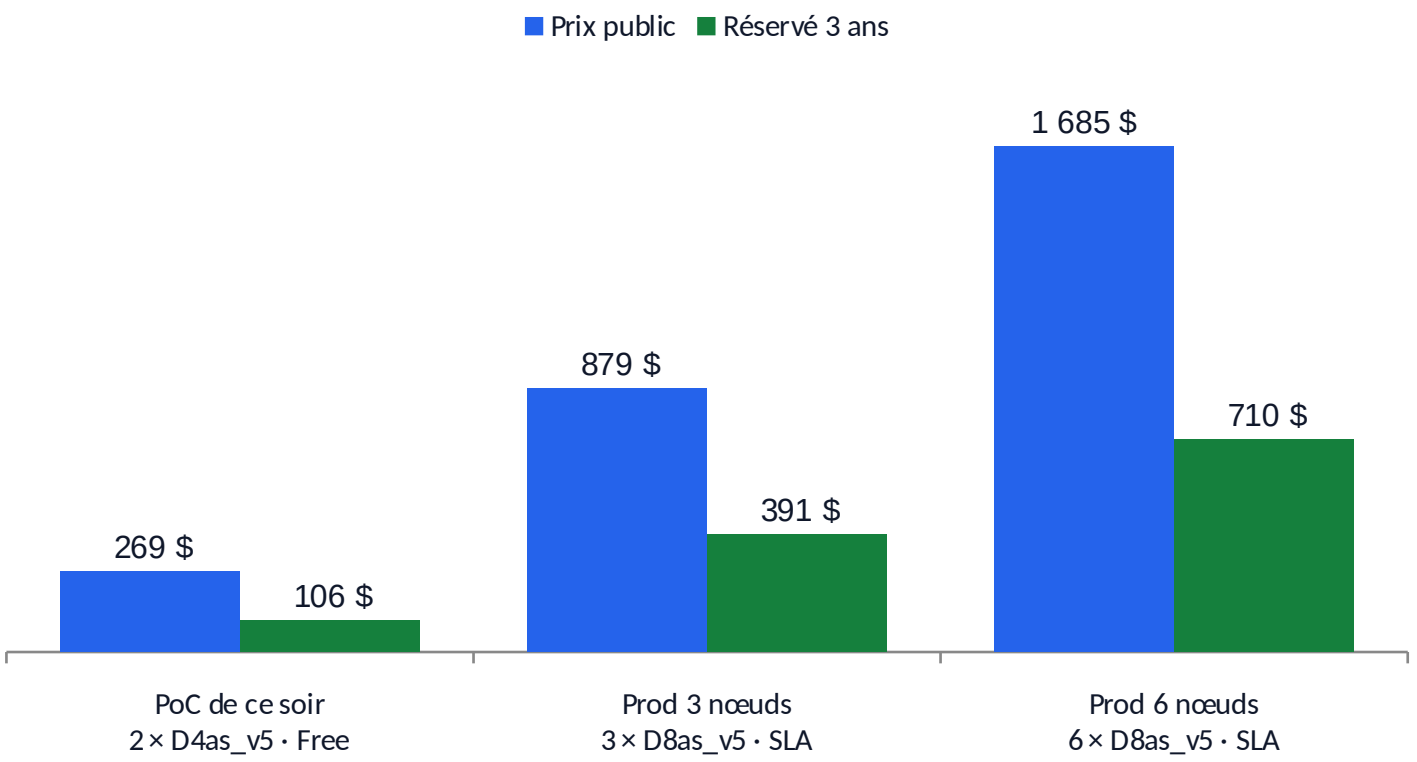
Épingler chaque version

API en alpha partout : charts, images, et CRD relus à chaque montée.

CE QUE ÇA COÛTE

Le socle coûte peu. Ce qui coûte, c'est l'inférence sans limite.

Compute AKS par mois — prix public et réservation 3 ans



Prix publics Azure (API Retail Prices), Sweden Central, USD, relevés en octobre 2026, Linux, 730 h/mois. Hors disques, load balancer, IP, logs, sortie réseau et inférence.

Ce qui change en prod

- plan de contrôle Standard : SLA, 73 $/mois
- nœuds 8 vCPU · 32 Go, un par zone
- réservé 3 ans : −60 % sur les nœuds

60 000 €

un week-end, une clé qui fuit, aucun plafond : ≈ 41 mois du cluster de prod à 6 nœuds, au prix public

La passerelle est l'assurance la moins chère du projet.

À RETENIR

Trois choses à emporter

1 Foundry pour les modèles, la passerelle pour le contrôle

Identité, plafonds, garde-fous et coûts en un point — pour tous les modèles et tous les outils.

2 Un agent est une ressource avec un cycle de vie

Publié, versionné, déployé, observé, retiré : kagent et agentregistry, comme un Deployment.

3 L'identité est le vrai chantier

Le login est facile ; propager l'utilisateur jusqu'à l'outil et à la facture, c'est là que se joue l'entreprise.

Merci !

Questions ?

Le dépôt complet — Terraform, manifestes, démos, tableau de bord, schémas d'architecture — est publié : scannez le QR code.

smartcloudarchitect.fr · blog.smartcloudarchitect.fr

Antoine LOIZEAU · Smart Cloud Architect

Code source et démos

`github.com/aloizeau/agentic-ai-azure-and-beyond-geneve-2026`

```
governed: true
```

```
identity: end-to-end
```

ANNEXE · CE QUI A FAIT BASCULER

Pour une plateforme Kubernetes, cinq raisons

1	**L'écosystème**	kagent (CNCF Sandbox), kmcp, agentregistry : des stacks IA standardisées, déployées comme n'importe quelle ressource Kubernetes.
2	**Un standard, pas un produit**	Gateway API : la compétence et les manifestes suivent d'un cloud à l'autre.
3	**L'autorisation par outil**	CEL (Common Expression Language) sur jwt.* et mcp.tool.name — les outils non autorisés disparaissent du tools/list.
4	**La fédération MCP**	Un seul endpoint pour Jira, Azure DevOps, SharePoint… au lieu d'une connexion par serveur.
5	**Rust**	~22 Mo de mémoire par instance, contre plusieurs Go pour un proxy Python.*

* Mesure publiée par Solo.io, sur un backend factice. À retenir : l'empreinte mémoire, pas le multiple de débit.

ANNEXE · REX TECHNIQUE

Six pièges que la documentation ne met pas en avant

« Azure AI Foundry » → Microsoft Foundry

Rôles renommés, GUID inchangés : assignez les rôles par GUID.

/models est retiré depuis le 26/08/2026

Utilisez /openai/v1/ — sans paramètre api-version.

Le scope a changé

https://ai.azure.com/.default, plus cognitiveservices.azure.com.

requested_access_token_version = 2

Sinon l'aud devient api://<id> : un 401 garanti.

capacity = 1 dans l'exemple officiel

1 000 jetons par minute : un seul chat suffit à saturer.

agentgateway n'est plus kgateway

AgentgatewayBackend et AgentgatewayPolicy, plus Backend ni TrafficPolicy.

ANNEXE · SOUVERAINETÉ

La souveraineté devient une ligne de configuration

`GlobalStandard`

Traitement possible dans n'importe quelle région Azure du monde

`gpt-5.6-sol`

`DataZoneStandard`

Traitement uniquement dans la zone de données UE

`terra · luna`

`Standard`

Traitement dans la géographie Azure choisie

`selon le modèle`

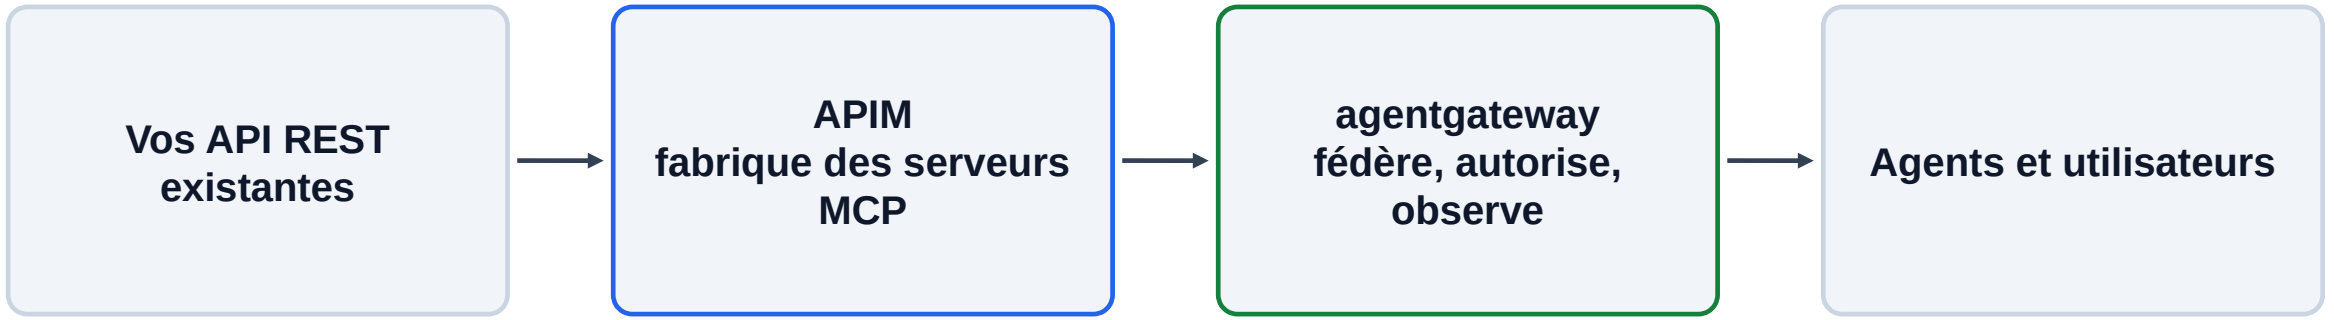
UE

DataZone borne le traitement à la zone UE. Le prix dépend du modèle et doit être vérifié dans Foundry.

« Global types: May be processed in any Azure region. »

Source : learn.microsoft.com — Foundry deployment types.

Deux couches, pas deux concurrents



APIM transforme un patrimoine d'API en outils d'agents. agentgateway gouverne ces outils à l'exécution, au plus près des agents, dans le cluster.

Architecture possible, pas celle du REX : à envisager si votre point de départ est un catalogue d'API.

ANNEXE · MODÈLE DANS LE CLUSTER

Un modèle dans le cluster, les mêmes règles

models/deploy/

```yaml
apiVersion: kaito.sh/v1beta1
kind: Workspace
metadata:
  name: workspace-phi-4-mini
  namespace: models
resource:
  instanceType: Standard_NV36ads_A10_v5
inference:
  preset:
    name: microsoft/Phi-4-mini-instruct
# + AgentgatewayBackend « custom » (providerOverride: kaito)
# + route /aks/v1 et les mêmes règles
```



Même passerelle, une route de plus

Les agents ne changent pas.



Pas de filtres Foundry ici

Seules les règles de la passerelle protègent ce modèle.



Le coût change de nature

≈ 4,16 $/h le GPU A10, 0 $ au jeton dans « Usage IA ».

ANNEXE · LE BILAN

Ce qui a marché, ce qui a fait mal

Ce qui a marché

- Un point d'entrée unique pour ~3 000 collaborateurs
- Des connecteurs SI réutilisables d'un projet à l'autre
- Des stacks IA standardisées, déployées par kagent
- Une gouvernance transverse, avec sa politique

Ce qui a fait mal

- Une documentation qui bouge plus vite que les projets
- Des API en alpha partout : épingler chaque version
- La propagation de l'identité Entra ID d'outil en outil
- L'imputation des coûts quand un agent agit pour quelqu'un